






IMPLEMENTAÇÃO DE DATA LAKEHOUSE COM DELTA LAKE



Prof. Adnan Jebailey



Aula 01

Data Warehousing, Data Lake, Lake House,
Estrutura Medalhão e Delta Lake (DLT)

Quem sou eu?


Adnan Jebailey é economista e mestre em Planejamento e Análise de Políticas Públicas pela UNESP. Especialista em pesquisa aplicada, ciência de dados e avaliação de políticas públicas, possui ampla experiência na coordenação de pesquisas de campo, produção de indicadores e análise estatística. Fundou os departamentos de Economia e Pesquisa das Associações Comerciais de Franca, São José do Rio Preto e Florianópolis, além de conduzir, há cinco anos, pesquisas de movimentação financeira e impacto econômico para a Prefeitura de São José do Rio Preto. Atuou como Coordenador de Dados e Pesquisa no Laboratório de Estudos em Economia Social (LEPES/USP Ribeirão Preto), Gestor de Implementação de Políticas de Dados Educacionais no Ministério da Educação, Gestor de Tecnologia, Dados e Estatística da Parceiros da Educação, desenvolvendo projetos com mais de 700 escolas públicas paulistas, e Coordenador de Dados e Estatísticas da Fundação Nacional de Seguros





Datawarehouse, DataLake e Lake House

Datawarehouse




O data warehouse surgiu para solucionar o problema dos silos de dados em grandes empresas e para simplificar a inteligência de negócios (BI) e a tomada de decisões analíticas.

No entanto, após a virada do século, os data warehouses não conseguiram acompanhar os formatos de dados mais recentes, como JSON, bem como novas modalidades de dados, como áudio e vídeo. Simplificando, os data warehouses tinham dificuldades para processar dados semiestruturados e não estruturados, que a maioria das empresas utilizava.

(GIRTEN 2024; LEE et al. 2024)



DataLake




O conceito de data lake surgiu para armazenar dados brutos (não processados) em uma ampla variedade de formatos (CSV, JSON, ORC, texto, binário) dentro de um sistema de arquivos distribuído, sendo a opção mais popular na época o formato CSV.

[...] os data lakes apresentavam governança de dados deficiente. Eram propensos a práticas de manipulação de dados descuidadas, resultando em muitas cópias caras dos mesmos conjuntos de dados, que frequentemente divergiam da fonte original. Como resultado, esses data lakes rapidamente ganharam o apelido de pântanos de dados.

(GIRTEN 2024; LEE et al. 2024)



Lakehouse




O lakehouse é uma arquitetura de gerenciamento de dados aberta que combina a flexibilidade, a relação custo-benefício e a escalabilidade de um data lake com o gerenciamento de dados, a aplicação de esquemas e as transações ACID de um data warehouse tradicional.

(DATABRICKS)

Ao combinar o melhor dos dois mundos, obtemos um sistema único que as equipes de dados podem utilizar para trabalhar com mais agilidade, já que podem usar os dados para sua finalidade específica sem precisar acessar múltiplos sistemas (o que sempre aumenta a complexidade)

(LEE et al. 2024)





Estrutura Medalhão





Figura 9-4. A arquitetura Medallion é uma estrutura procedural que fornece portões e níveis de qualidade desde o ponto de ingestão até o produto de dados curado e desenvolvido especificamente para esse fim.

Estrutura Medalhão




A arquitetura em medalhão é um padrão de projeto de dados usado para organizar logicamente os dados no lakehouse. Isso é realizado por meio de uma série de camadas de dados isoladas, que fornecem uma estrutura para o refinamento progressivo dos conjuntos de dados.

A arquitetura em medalhão oferece uma estrutura flexível para lidar com o aprimoramento progressivo de dados de forma estruturada. Vale ressaltar que, embora seja comum observar três camadas (bronze, prata e ouro), não há regra que determine que todos os casos de uso exijam três camadas

(LEE et al. 2024)



Camada Bronze




A camada de bronze representa o ponto inicial da nossa linhagem de dados dentro do ambiente do lago. Uma prática comum aqui é aplicar transformações mínimas (se houver) aos dados. Essas são as transformações que não podem ser ignoradas, como converter o formato de origem para um tipo compatível para gravação no Delta Lake.

No caso de importarmos dados não tipados — como em arquivos CSV ou JSON — a camada bronze é extremamente importante para filtrar dados corrompidos e outros problemas.

(LEE et al. 2024)



Camada Prata




Independentemente do motivo pelo qual limpamos e filtramos os dados da camada bronze, os resultados dos nossos esforços fornecem aos nossos stakeholders dados mais consistentes e confiáveis para impulsionar seus inúmeros casos de uso. Podemos considerar a camada prata como a primeira camada estável no medalhão.arquitetura.

(LEE et al. 2024)



Camada Ouro



É comum que os dados de relatórios sejam armazenados na camada de ouro. Esses são os dados que nós (e a empresa) mais valorizamos. É nossa responsabilidade garantir que forneçamos tabelas (ou visualizações) específicas para assegurar que os dados críticos para os negócios estejam disponíveis, sejam confiáveis e precisos.


A camada de ouro pode ser implementada usando tabelas físicas ou tabelas virtuais (views). Os requisitos de desempenho irão, em última análise, ditar o uso de tabelas versus views, mas uma view é suficiente para atender às necessidades de muitos casos de uso da camada de ouro.

(LEE et al. 2024)



Delta Lake e DLT


Delta Lake



Delta Lake não é exatamente um tipo de arquitetura como Data Lake, Data Warehouse ou Lakehouse; é uma tecnologia/camada de armazenamento que adiciona recursos aos arquivos armazenados em um Data Lake, principalmente sobre arquivos Parquet. Ele fornece recursos como transações ACID, versionamento/time travel, schema enforcement, schema evolution e operações de UPDATE/DELETE/MERGE. Por isso, tecnologias como o Databricks utilizam Delta Lake como uma das bases para implementar uma arquitetura Lakehouse: Data Lake + Delta Lake + processamento/SQL/governança = uma plataforma Lakehouse.



Delta Live Tables (DLT)




O DLT é um framework declarativo que visa simplificar as operações de desenvolvimento e manutenção de um pipeline de dados, abstraindo grande parte das complexidades repetitivas. Por exemplo, em vez de declarar como transformar, enriquecer e validar dados, os engenheiros de dados podem declarar quais transformações aplicar aos dados recém-chegados. Além disso, o DLT oferece suporte para garantir a qualidade dos dados, evitando que um data lake se torne um pântano de dados. O DLT permite que as equipes de dados escolham como lidar com dados de baixa qualidade, seja imprimindo uma mensagem de aviso nos logs do sistema, descartando dados inválidos ou interrompendo completamente a execução de um pipeline de dados

(GIRTEN 2024)



Delta Live Tables (DLT)



A estrutura gerencia automaticamente a orquestração de tarefas, a criação de clusters e o tratamento de exceções, permitindo que os engenheiros de dados se concentrem na definição de transformações, enriquecimento de dados e lógica de validação de dados.

(GIRTEN 2024)





Referências

REFERÊNCIAS BIBLIOGRÁFICAS

GIRTEN, Will. Building modern data applications using Databricks Lakehouse.
Birmingham: Packt Publishing, 2024. 246 p.

LEE, Denny; WENTLING, Tristen; HAINES, Scott; BABU, Prashanth. Delta Lake: the
definitive guide. Sebastopol: O'Reilly Media, 2024. 382 p.

