






IMPLEMENTAÇÃO DE DATA LAKEHOUSE COM DELTA LAKE



Prof. Adnan Jebailey



Aula 03

Gestão de Dados, Otimização e Conectores


Gestão de Dados em Delta

Create, Read, Update e Delete (CRUD) no Delta



Os arquivos Delta permitem realizar operações de CRUD (Create, Read, Update e Delete) utilizando SQL, proporcionando uma experiência semelhante à manipulação de tabelas relacionais. Por meio do SQL, é possível criar tabelas Delta com `CREATE TABLE`, consultar os dados utilizando `SELECT`, inserir novos registros com `INSERT`, atualizar informações existentes com `UPDATE` e remover registros com `DELETE`.

Outras Operações




Time Travel: verificar versões anteriores ou como os dados em uma tabela estavam em um determinado momento, com menos esforço necessário para criar backups de arquivos e sem depender dos utilitários de backup nativos do serviço de nuvem. (VERSION AS OF e TIMESTAMP AS OF)

Merge: [...] permite encadear múltiplas operações em um conjunto de dados com um conjunto unificado de condições de correspondência em toda a cadeia. Isso permite controlar condicionalmente as ações com base no grau de correspondência.

History and Details: [...] revisar informações como o esquema de uma tabela, qual versão de leitor ou gravador está implementada para ela ou quaisquer outras propriedades que possam estar definidas

(LEE et al. 2024)

Outras Operações



Tables Constrains: No Delta Lake, você pode aplicar restrições de tabela para garantir a integridade dos dados e definir regras para suas tabelas. As restrições de tabela ajudam a garantir que os dados estejam em conformidade com condições ou requisitos específicos (NOT NULL e CHECK).

Reordering Columns: [...] você pode especificar onde a coluna deve ser posicionada em relação às outras colunas da tabela.


Column Mapping: O mapeamento de colunas no Delta Lake permite flexibilidade na nomenclatura e na evolução das colunas da tabela sem a necessidade de reescrever os arquivos Parquet subjacentes. Isso permite que as tabelas Delta tenham nomes de coluna diferentes dos nomes das colunas correspondentes nos arquivos Parquet.

Dropping a column: remover colunas.



Otimização

Particionamento




O Delta Lake suporta particionamento, o que melhora o desempenho das consultas ao organizar os dados com base em categorias em determinadas colunas. Você pode particionar tabelas do Delta Lake com base em uma ou mais colunas, como **data**, região ou qualquer outro atributo relevante. O particionamento pode melhorar significativamente o desempenho das consultas, especialmente ao lidar com grandes conjuntos de dados. Você pode especificar as colunas de particionamento ao criar a tabela ou usar o método ``partitionBy`` ao gravar os dados.



(CHADHA, 2024)

Z-Order




A ordenação Z é uma técnica do Delta Lake que organiza os dados com base em colunas selecionadas para melhorar o desempenho das consultas. Ela agrupa dados relacionados. Fisicamente, isso reduz a quantidade de dados que precisa ser lida durante as consultas. Funciona bem para colunas de alta cardinalidade e beneficia operações de filtragem, junção e agregação. A ordenação Z é uma otimização de escrita de dados que requer a consideração de padrões de consulta e colunas selecionadas para resultados ideais.

Cada vez que a ordenação Z é executada, ela tenta criar uma nova maneira de organizar os dados em todos os arquivos dentro de uma partição. Isso significa que mesmo arquivos existentes que já faziam parte de uma operação de ordenação Z serão reorganizados juntamente com os novos arquivos. A operação Z-ORDER não é idempotente.



(CHADHA, 2024)

Observações sobre o Z-Order




Impacto no desempenho: As operações de ordenação Z podem consumir muitos recursos e tempo, especialmente em tabelas grandes. Executar essas operações com frequência ou em tabelas com alta carga de trabalho pode afetar o desempenho das consultas e o desempenho geral do sistema.

Escolher as colunas certas: Selecionar as colunas corretas para a ordenação Z é crucial. Se mal escolhidas, podem não gerar melhorias significativas no desempenho das consultas ou, em alguns casos, até mesmo piorá-lo. Compreender os padrões de consulta e de acesso aos dados é importante para tomar decisões informadas.

Distribuição de dados: Distribuições desiguais de dados nas colunas selecionadas podem levar a um posicionamento desbalanceado dos dados após a ordenação Z, reduzindo sua eficácia. Se os valores dos dados não estiverem distribuídos uniformemente, algumas partições podem acabar com arquivos muito maiores do que outras, impactando o desempenho da consulta.

(CHADHA, 2024)

Observações sobre o Z-Order




Evolução dos dados: a ordenação Z não é dinâmica; ela permanece estática após a gravação dos dados. Se a distribuição dos dados mudar significativamente ao longo do tempo, a ordenação Z inicialmente bem otimizada pode se tornar menos eficaz, exigindo reavaliação e reotimização periódicas.

Sobrecarga de metadados: Tanto as operações de otimização quanto as de ordenação Z podem introduzir sobrecarga adicional de metadados, pois precisam rastrear as alterações feitas no layout da tabela. Isso pode impactar os requisitos de armazenamento para a tabela Delta Lake.

Conectores

Conectores



Há um bom número de conectores e integrações que permitem a interoperabilidade com o formato e os protocolos da tabela Delta, independentemente de onde as operações sejam iniciadas.



(LEE et al. 2024)



Referências

REFERÊNCIAS BIBLIOGRÁFICAS

CHADHA, Pulkit. Data engineering with Databricks Cookbook. Birmingham: Packt Publishing, 2024. 438 p.

LEE, Denny; WENTLING, Tristen; HAINES, Scott; BABU, Prashanth. Delta Lake: the definitive guide. Sebastopol: O'Reilly Media, 2024. 382 p.

