






IMPLEMENTAÇÃO DE DATA LAKEHOUSE COM DELTA LAKE



Prof. Adnan Jebailey



Aula 04


Delta Live Tables (DLT), Configuração e Processamento



Delta Live Table

Autoloader e CDC/SCD

Delta Live Table (DLT)



A tecnologia DLT simplifica a ingestão de dados de diversas fontes de entrada [...] podemos usar a tecnologia de registro distribuído (DLT) para ingerir incrementalmente novos dados que chegam a um local de armazenamento em nuvem.

(CHADHA, 2024)

O Delta Live Tables (DLT) passou por uma evolução de nomenclatura dentro da plataforma Databricks e atualmente é apresentado como Lakeflow Spark Declarative Pipelines. A mudança não representa o fim do conceito, mas uma ampliação e reorganização de suas funcionalidades, mantendo a proposta de construção de pipelines de dados de forma declarativa, incremental e orientada a dependências, com recursos como Streaming Tables, Materialized Views, Auto Loader, Expectations e processamento de CDC. Em códigos e materiais mais antigos, ainda é comum encontrar a nomenclatura DLT e a biblioteca dlt, enquanto os novos pipelines utilizam as APIs pyspark.pipelines (dp).

AutoLoader




Uma das principais funcionalidades da plataforma Databricks Data Intelligence é o Auto Loader, um recurso de ingestão simples, porém poderoso mecanismo para leitura eficiente de arquivos de entrada do armazenamento em nuvem.

O Auto Loader infere automaticamente o esquema da fonte de dados e rastreia as alterações na definição do esquema em um local de armazenamento separado. Nos bastidores, o Auto Loader amostra até os primeiros 1.000 objetos de arquivo na nuvem para inferir a estrutura do esquema de uma fonte de arquivo na nuvem. Para formatos semiestruturados, como JSON, onde o esquema pode muda com o tempo, isso pode aliviar um grande fardo para as equipes de engenharia de dados, pois elas não precisarão manter uma definição atualizada do esquema mais recente.

(CHADHA, 2024)

AutoLoader

No modo de notificação, o Databricks Auto Loader usa um fluxo de eventos para monitorar arquivos novos e não processados no armazenamento em nuvem.



(CHADHA, 2024)

CDC




A captura de dados de mudança (CDC) é uma técnica para capturar e processar as alterações feitas em uma fonte de dados, como um banco de dados ou um sistema de arquivos. O CDC pode ser útil em diversos cenários, como sincronização de dados, replicação, auditoria e análise.

Delta Lake apoia o CDC por meio de um recurso chamado feed de dados de alteração (CDF , na sigla em inglês) permite que as tabelas Delta rastreiem alterações em nível de linha alterações entre versões de uma tabela Delta. Quando habilitado em uma tabela Delta, o tempo de execução registra "eventos de alteração" para todos os dados gravados na tabela.

(CHADHA, 2024)

SCD (1 e 2)



A DLT oferece uma nova API para aplicar automaticamente alterações às tabelas subsequentes, inclusive lidando com dados fora de ordem com base em um conjunto de um único elemento ou mais colunas de sequência. Dimensões de mudança lenta (SCDs) são dimensões em tradicional com armazenamento de dados que permite rastrear o panorama atual e histórico dos dados ao longo do tempo


CDC e SCD



CDC (Change Data Capture) identifica e registra quais dados foram inseridos, alterados ou excluídos na origem, capturando as mudanças ocorridas ao longo do tempo. Já o SCD (Slowly Changing Dimension) é uma estratégia de modelagem que define como essas mudanças serão armazenadas no destino, principalmente em dimensões: o SCD Tipo 1 sobrescreve o valor anterior, enquanto o SCD Tipo 2 mantém o histórico das versões do registro.

Configuração de Cluster e Processamento

Configuração de Cluster




Existem três tipos de configurações de cluster que podem ser expressas nas configurações do pipeline: a configuração de cluster de atualização, a configuração de cluster de manutenção e uma terceira opção que atua como uma configuração de cluster padrão, aplicando configurações generalizadas tanto para clusters de atualização quanto para clusters de manutenção. O esquema para essa configuração JSON segue de perto o da API REST do Databricks Clusters.

Além de configurar os atributos físicos de um cluster, como o número de nós de trabalho e os tipos de instâncias de máquinas virtuais, a configuração do cluster também pode conter configurações avançadas do Spark



(CHADHA, 2024)

Configuração de Cluster




Auto-Optimized Shuffle (AOS). O AOS dimensionará automaticamente o número de partições de shuffle do Spark em tempo de execução, o que pode melhorar o desempenho durante transformações complexas do Spark, como junções, agregações e operações de mesclagem.



(CHADHA, 2024)


Databricks Asset Bundles (DAB)



O **Databricks Asset Bundles (DAB)** é uma forma de definir, configurar e implantar recursos do Databricks como código, permitindo versionar em Git e automatizar a criação e atualização de elementos como Jobs, Pipelines, notebooks, arquivos e configurações de infraestrutura. Em vez de configurar cada recurso manualmente pela interface do Databricks, o DAB utiliza arquivos de configuração, normalmente em YAML, para descrever o ambiente e os recursos, facilitando a reprodutibilidade, padronização e implantação entre ambientes, como desenvolvimento, homologação e produção.



Processamento




O modo de processamento determina a frequência com que as tabelas e as visualizações materializadas dentro de um pipeline são atualizadas. A DLT oferece duas opções. tipos de tubulação

Modos de processamento: modo de processamento acionado e modo de processamento contínuo


O modo de **processamento acionado** atualizará os conjuntos de dados contidos em um pipeline uma única vez e, em seguida, encerrará imediatamente o cluster provisionado para executar o pipeline, liberando os recursos computacionais de volta para o provedor de nuvem e, assim, evitando a cobrança de custos adicionais de nuvem.



(CHADHA, 2024)



Processamento



o modo de **processamento contínuo** alocará recursos computacionais para atualizar os conjuntos de dados dentro de um pipeline, mas continuará a ser executado indefinidamente, processando dados e atualizando-os. Tabelas e visualizações materializadas são processadas conforme os dados chegam da fonte. Um pipeline de processamento contínuo manterá os recursos computacionais em funcionamento e continuará incorrendo em custos de nuvem, com a contrapartida de uma mínima desatualização dos dados. Esse tipo de modo de pipeline deve ser selecionado quando a latência dos dados for priorizada em relação aos custos de computação em nuvem para um pipeline de dados específico.



(CHADHA, 2024)



Referências

REFERÊNCIAS BIBLIOGRÁFICAS

CHADHA, Pulkit. Data engineering with Databricks Cookbook. Birmingham: Packt Publishing, 2024. 438 p.

