






IMPLEMENTAÇÃO DE DATA LAKEHOUSE COM DELTA LAKE



Prof. Adnan Jebailey




Aula 06

**Controle de Acesso (Governança), Unity Catalog
(Monitoramento) e Estrutura Medalhão**

Controle de Acesso

Segurança dos Dados




Pense nessa mitigação de riscos como uma história simples: para impedir o acesso não autorizado a um local físico (entidade: casa, carro, escritório), controles de acesso (mecanismo de fechadura) foram introduzidos para proteger um espaço físico (recurso) e fornecer entrada autorizada somente quando a confiança puder ser confirmada (chave, credenciais).

Em termos mais simples, a única coisa que impede uma intrusão é a chave . Embora uma chave dê acesso a um determinado espaço físico por meio de uma fechadura, quem a possui também precisa saber a localização física do recurso protegido; caso contrário, a chave não tem utilidade. Este é um exemplo de segurança do local e, como modelo mental, é útil na elaboração de um plano para o modelo de governança e segurança em camadas dos recursos contidos em nossa lakehouse. Afinal, a lakehouse é um espaço seguro que protege o que nos é mais precioso somente se governarmos coletivamente os recursos que ela contém.

(LEE, 2024)

Governança dos Dados



A governança de dados é definido como um guarda-chuva que reúne vários princípios e práticas, bem como ferramentas e fluxos de trabalho, para governar os ativos de dados de uma organização ao longo de todo o seu ciclo de vida. O ciclo de vida dos dados engloba toda a jornada de ponta a ponta, da criação à exclusão, incluindo todas as transformações e qualquer acesso e utilização dos dados em qualquer ponto ao longo do processo (durante a existência dos dados).

(LEE, 2024)




Figura 12-2. Gerenciamento do ciclo de vida dos dados

(LEE, 2024)

Acessos



A governança sobre quais operações um usuário ou grupo pode executar é gerenciada por meio de privilégios. Utilizando os seguintes grupos de sintaxe **SQL: linguagem de controle de dados (DCL), linguagem de definição de dados (DDL) e linguagem de manipulação de dados (DML).**

(LEE, 2024)

DCL, DDL e DML

Linguagem de Controle de Dados (DCL): Sintaxe especial usada para o gerenciamento de acesso em sistemas do tipo SQL. Através do uso de **GRANT** e **REVOKE** operações, um conjunto de ações autorizadas (privilégios) está associado a um conjunto de USERS ou GROUPs, permitindo-lhes executar operações definidas por DDL e DML, ou removendo um ou mais privilégios que haviam sido concedidos anteriormente.


Linguagem de Definição de Dados (DDL): A sintaxe fornece os seguintes padrões de ações: CREATE, ALTER, DROP, COMMENT, e RENAME. Usamos DDL em ação direta e indiretamente por meio das bibliotecas complementares Delta Scala, Python e Rust.

Linguagem de Manipulação de Dados (DML): A sintaxe fornece privilégios para controlar as operações que um usuário ou grupo pode executar em um recurso usando o padrão. ações SELECT, INSERT, UPDATE, e DELETE:..

(LEE, 2024)

Gestão de Identidade

Controle de Acessos baseado em funções



Controles de acesso baseados em funções (Role-Based Access Control - RBAC) são utilizadas para aprovar ou negar o acesso ao sistema e para autorizar um subconjunto de permissões em recursos necessários para o desempenho das funções de personas específicas que utilizam uma ou mais funções dentro de uma organização

Para a lakehouse, considere os papéis que desempenhamos em nossos trabalhos diários (engenheiro, cientista, analista, funções de negócios), as equipes e organizações das quais fazemos parte, as linhas divisórias lógicas de nossos negócios (que podem ajudar a estabelecer domínios de dados), o ambiente de execução de nossos sistemas, serviços e produtos de dados (desenvolvimento, teste, produção) e, por fim, a classificação dos dados que gerenciamos e acessamos (acesso irrestrito, restrito, sensível, altamente sensível). As linhas que definem um papel podem ser um pouco imprecisas às vezes e, por esse motivo, o R em RBAC também pode denotar recurso .

(LEE, 2024)

Gestão de Identidade

Funções ao entorno das pessoas

Entendimento **O quem, o quê, onde, como e porquê se** simplificam quando abstraímos os papéis associados às personas comuns dentro de uma organização.

O processo para autorizar o acesso a um determinado ativo de dados (recurso) em nossa lakehouse pode ser determinado pela combinação dos seguintes fatores:


- O papel e a responsabilidade do usuário (quem e o quê)
- A localização do recurso (bucket e prefixo) (onde)
- O ambiente em que operam (desenvolvimento, teste, produção)
- As classificações de dados (geralmente disponíveis, restritos, sensíveis, etc.), que denotam o quê
- A operação (ação): ler (visualizar), modificar (ler, escrever) ou administrar (ler, escrever, criar ou excluir) como o método.

Portanto, lembre-se: precisamos sempre ter em mente **o quem , o quê , onde e como , bem como o se .**

(LEE, 2024)


Gestão de Identidade

Funções ao entorno das pessoas



Pense da seguinte forma: se concedermos acesso a uma determinada identidade (quem), quais operações são necessárias para realizar um determinado conjunto de tarefas (como), e em que ambiente (onde) elas precisam de acesso em nível de usuário versus acesso de usuário sem interface gráfica? E, por fim, quais são os riscos potenciais envolvidos em conceder acesso em nível de leitura versus acesso em nível de leitura e gravação?

Classificação dos Dados




Os classificadores a seguir são uma maneira útil de identificar que tipo de dados estão armazenados em um recurso em um local específico no data lake.

Para simplificar, vamos pensar na classificação de dados em termos do padrão de um semáforo. Um semáforo sinaliza ao motorista para continuar (verde), reduzir a velocidade (amarelo) ou parar (vermelho). Por analogia, ao pensar em como controlar o acesso aos nossos dados, o padrão do semáforo oferece um modelo mental simples para etiquetar ou rotular (identificar) dados que podem ser verdes, amarelos ou vermelhos.

(LEE, 2024)

Classificação dos Dados




Por exemplo, o acesso a dados classificados como “verdes” poderia ser automatizado, desde que existam verificações adequadas para garantir que os recursos não vazem dados sensíveis. Um exemplo prático de dados “verdes” seriam os dados sobre terremotos e riscos naturais disponibilizados ao público pelo Serviço Geológico dos Estados Unidos (USGS) - dados públicos.

O acesso a dados classificados como “amarelos” ou “vermelhos” exigiria que o beneficiário considerasse quem teria acesso, por que precisariam desse acesso e por quanto tempo, e como o acesso poderia beneficiar ou prejudicar a organização. Em caso de dúvida, sempre considere a hipótese. Se concedermos acesso a esses dados, confiamos que o(s) beneficiário(s) agirão corretamente?

Unity Catalog


Unity Catalog



O Unity Catalog é uma solução de governança que simplifica a segurança dos dados em seu data warehouse, organizando as políticas de acesso a objetos do espaço de trabalho em um único painel administrativo. Além das políticas de acesso, o Unity Catalog foi projetado com foco em auditoria robusta, permitindo que os administradores registrem todos os padrões de acesso dos usuários aos objetos do espaço de trabalho. Dessa forma, é possível observar padrões de acesso, uso do espaço de trabalho e faturamento em todos os espaços de trabalho do Databricks. O Unity Catalog também permite que profissionais de dados descubram conjuntos de dados em toda a organização, rastreiem a linhagem dos dados, visualizem diagramas de relacionamento de entidades, compartilhem conjuntos de dados selecionados e monitorem a integridade dos sistemas.

(GIRTEN, 2024)

Unity Catalog



Um dos principais pontos fortes do Unity Catalog é que, uma vez que os dados da sua organização estejam no Unity Catalog, eles são protegidos por padrão – nenhum processo, seja interno ao espaço de trabalho do Databricks ou externo que interaja com dados de fora da Plataforma de Inteligência de Dados do Databricks, tem acesso aos dados, a menos que o acesso tenha sido explicitamente concedido por um administrador de dados. O Unity Catalog foi projetado para abranger todo o perímetro do seu ambiente de dados, de espaço de trabalho a espaço de trabalho e além do espaço de trabalho do Databricks, ficando sobreposto aos dados da sua organização, de forma que um modelo de governança único possa ser aplicado de maneira simples e consistente a todas as partes que acessam os dados da sua organização no ambiente de dados .

(GIRTEN, 2024)

O Databricks passou a habilitar automaticamente o Unity Catalog para novos workspaces. A documentação atual informa que workspaces criados após 8 de novembro de 2023 são automaticamente habilitados no AWS





Figura 5.1 – O Unity Catalog fornece uma camada de governança única e unificada sobre os dados em nuvem da sua organização.

(GIRTEN, 2024)

Unity Catalog



O objetivo do Unity Catalog era resolver o problema de implementar uma solução completa de governança de dados de ponta a ponta que abrange todos os espaços de trabalho de uma organização, eliminando a redundância de ter que redefinir as políticas de acesso a dados para cada espaço de trabalho do Databricks. Em vez disso, com o Unity Catalog, os administradores de dados podem definir os controles de acesso a dados uma única vez em um local centralizado e ter a tranquilidade de que eles serão aplicados de forma consistente em toda a organização, independentemente do recurso computacional ou mecanismo de processamento usado para interagir com os conjuntos de dados no Unity Catalog.

(GIRTEN, 2024)




Figura 5.2 – O Unity Catalog centraliza as políticas de acesso a dados que são então aplicadas de forma consistente em vários espaços de trabalho do Databricks.

(GIRTEN, 2024)


Funções de Uso

Segurança por padrão: os usuários não terão acesso à leitura de dados de nenhuma forma de computação sem usar um cluster habilitado para Unity Catalog (os clusters do Unity Catalog são abordados na seção seguinte) e sem ter recebido permissão específica para usar e selecionar dados de um conjunto de dados específico.

Interfaces de administração intuitivas: As políticas de acesso a dados no Unity Catalog estão totalmente integradas ao SQL do American National Standards Institute (ANSI), permitindo aos administradores definir permissões de acesso a dados em objetos de banco de dados comuns, como catálogos, bancos de dados, tabelas, funções e visualizações. As permissões de acesso a dados também podem ser definidas usando a interface de administração do aplicativo web do Databricks ou ferramentas de implantação automatizadas, como o Terraform.

(GIRTEN, 2024)

Funções de Uso



Descoberta de dados: O Unity Catalog facilita para os administradores de dados a marcação de conjuntos de dados com metadados descritivos, permitindo que usuários em toda a sua organização pesquisem e descubram conjuntos de dados disponíveis para eles.

Auditoria robusta: o Unity Catalog captura automaticamente os padrões de acesso e as operações de dados em nível de usuário, permitindo que os administradores visualizem e auditem o comportamento do usuário à medida que ele interage com os dados.

Rastreamento da linhagem de dados: Rastrear como as tabelas e colunas são geradas a partir de fontes upstream é importante para garantir que os conjuntos de dados downstream sejam formados usando fontes confiáveis. O Unity Catalog simplifica o rastreamento de dados e ativos do espaço de trabalho por meio de suas robustas APIs de linhagem de dados e tabelas de sistema.

(GIRTEN, 2024)


Funções de Uso



Observabilidade: Como o Unity Catalog abrange vários espaços de trabalho do Databricks, ele pode agregar métricas do sistema e eventos de auditoria em um conjunto centralizado de tabelas somente leitura para monitoramento e observabilidade do sistema, chamadas de tabelas do sistema.

(GIRTEN, 2024)

Tags nos objetos de dados



O Unity Catalog oferece recursos úteis de catalogação de dados que permitem aos administradores de dados vincular metadados descritivos a conjuntos de dados e outros objetos protegíveis, como catálogos, volumes ou modelos de aprendizado de máquina. Ao atribuir tags descritivas a conjuntos de dados e outros objetos protegíveis, os usuários de toda a sua organização podem pesquisar e descobrir ativos de dados que podem ser úteis em suas atividades diárias. Isso ajuda a promover a colaboração entre equipes, economizando tempo e recursos, pois evita a necessidade de recriar ativos de dados semelhantes para concluir uma determinada atividade. O Unity Catalog oferece suporte a tags nos seguintes objetos de dados: catálogos, bancos de dados, tabelas, volumes, visualizações e modelos de aprendizado de máquina.

(GIRTEN, 2024)

Auditoria, Monitoramento e Observabilidade



A observabilidade é outro ponto forte do Unity Catalog e é implementada no Databricks usando tabelas de sistema. As tabelas de sistema são um conjunto de tabelas somente leitura em um espaço de trabalho do Databricks que capturam os dados operacionais sobre as atividades dentro dos seus espaços de trabalho. Além disso, as tabelas de sistema registram dados de todos os espaços de trabalho dentro de uma conta do Databricks, servindo como uma única fonte de verdade para recuperar dados operacionais referentes aos seus espaços de trabalho.

(GIRTEN, 2024)

Auditoria, Monitoramento e Observabilidade



system.access.audit: Quem fez o quê

system.access.table_lineage: De onde veio / para onde foi o dado

system.access.column_lineage: Linhagem por coluna

system.billing.usage: Consumo e custo


system.workflow.job_runs: Execução dos Jobs

system.workflow.task_runs: Execução das Tasks

system.compute.clusters: Histórico dos clusters

Estrutura Medalhão

Indicação de Leitura



Objetivos de cada camada



-  **Bronze** → preservar a verdade da fonte
-  **Silver** → construir a verdade confiável dos dados
-  **Gold** → entregar a verdade contextualizada para o negócio

(STRENGTHOLT, 2025)

Camada Bronze: preservar a origem



Objetivo: manter os dados o mais próximos possível da fonte.

Deve-se prezar por:

- Fidelidade: preservar o dado como foi recebido.
- Rastreabilidade: registrar origem, data/hora de ingestão, arquivo, sistema etc.
- Historicização: permitir recuperar o estado passado dos dados.
- Reprocessamento: os dados posteriores devem poder ser reconstruídos a partir da Bronze.
- Schema management: lidar com evolução e mudanças de esquema sem destruir o dado original.
- Imutabilidade / mínimo de transformação: evitar aplicar regras de negócio nessa camada.

Pergunta que a Bronze responde: “O que recebemos da fonte?”

(STRENGHOLT, 2025)

Camada Silver: qualificar e harmonizar



Objetivo: transformar dados brutos em dados confiáveis e consistentes.

Deve-se prezar por:

- Qualidade: tratar nulos, erros, duplicidades e inconsistências.
- Padronização: tipos, formatos, códigos e nomenclaturas.
- Integração: combinar diferentes fontes e resolver entidades/chaves.
- Conformidade: criar uma visão consistente dos dados da organização.
- Historizar corretamente: tratar alterações dos registros quando necessário.
- Modelo adequado: 3NF, Data Vault ou outro modelo, conforme o caso de uso.
- Regras técnicas e de negócio bem definidas: aqui ocorre a maior parte da transformação.
-

Pergunta que a Silver responde: “Qual é a versão limpa, consistente e integrada desses dados?”

(STRENGHOLT, 2025)

Camada Gold: entregar valor ao negócio



Objetivo: disponibilizar dados curados e orientados ao consumo.

Deve-se prezar por:

- Orientação ao negócio: representar conceitos e métricas relevantes para os usuários.
- Modelo de consumo: frequentemente dimensional, como Star Schema.
- Performance: otimizar para consultas e ferramentas de BI.
- Semântica: métricas, dimensões e regras devem estar claramente definidas.
- Governança: dados e indicadores devem ser documentados e controlados.
- Reutilização: evitar que cada dashboard recrie sua própria regra de negócio.
- Adequação ao consumidor: BI, relatórios, aplicações, ciência de dados etc.
-

Pergunta que a Gold responde: “Como transformamos esses dados em informação pronta para consumo?”

(STRENGHOLT, 2025)

Referências

REFERÊNCIAS BIBLIOGRÁFICAS

GIRTEN, Will. Building modern data applications using Databricks Lakehouse: develop, optimize, and monitor data pipelines on Databricks. Birmingham: Packt Publishing, 2024. 246 p. ISBN 978-1-80107-323-3.

LEE, Denny; WENTLING, Tristen; HAINES, Scott; BABU, Prashanth. Delta Lake: the definitive guide: modern data lakehouse architectures with data lakes. Sebastopol: O'Reilly Media, 2024. 382 p. ISBN 978-1-098-15194-2.

STRENGTHOLT, Piethein. Building medallion architectures: designing data platforms for data and AI. Sebastopol: O'Reilly Media, 2025.