






IMPLEMENTAÇÃO DE DATA LAKEHOUSE COM DELTA LAKE

CASO CONCRETO



Prof. Adnan Jebailey



Aula 07

Aplicação do conhecimento em um caso concreto

Caixa de Ferramentas

Caixa de Ferramentas (Databricks)

Conceitos e Evolução Lakehouse	Microbatchs e Jobs Orquestrados / Merge	Operações de Recuperação de Histórico e Detalhes	Controles de Acesso (Persona e Grupo)
Particionamento e Z-Order	Conectores	LakeFlowPipeline (DLT)	Conceitos de Estrutura Medalhão
Autoader	CDC e SCD	DAB (CLI)	Monitoramento e Auditoria
Tipos de Processamento (Acionado ou Contínuo)	Expectations (Qualidade)	Propriedades das Tabelas	Substituição, Restauração e Vácuo

O Caso

O desafio

Do zero a um departamento de dados

Uma entidade do terceiro setor deseja produzir estimativas e projeções sobre os impactos da Reforma Tributária na economia brasileira, observando a economia pelo lado da produção das empresas.

Para isso, será necessário construir uma infraestrutura capaz de:

- coletar dados de empresas;
- armazenar grandes volumes de informações;
- garantir qualidade e rastreabilidade;
- transformar dados brutos em informações analíticas;
- disponibilizar dados para análises econômicas.

O desafio: construir essa estrutura praticamente do zero.



A parceria




Onde estão os dados?

A entidade estabelece uma parceria com a Base dos Dados para utilizar sua infraestrutura de dados.

Entre as fontes disponíveis está a base de CNPJ, contendo informações dos estabelecimentos empresariais brasileiros.

Isso permite trabalhar com informações como: CNPJ; situação cadastral; CNAE; município; UF; endereço; data de início da atividade; matriz/filial; entre outras.

A decisão tecnológica



Como construir essa infraestrutura?

A organização decide utilizar:

Databricks Free Edition


como ambiente de desenvolvimento da plataforma de dados.

E utilizar:

Lakeflow Declarative Pipelines / DLT

para construir os pipelines de dados.

A equipe



Quem vai trabalhar com os dados?

A organização inicialmente terá apenas duas pessoas:

Engenheiro de Dados - Responsável por: ingestão; pipelines; armazenamento; qualidade; automação; arquitetura; governança.

Analista de Dados - Responsável por: exploração dos dados; indicadores; consultas; análises econômicas; visualizações; produção de evidências para os estudos.

The background features a dark navy blue field with a light brown grid. In the top-left corner, there is a 7x7 grid of white dots. In the bottom-right corner, there is a 3x3 grid of white dots. Large, overlapping light blue and orange circular shapes are positioned in the top-right and bottom-left corners.

Obrigado!