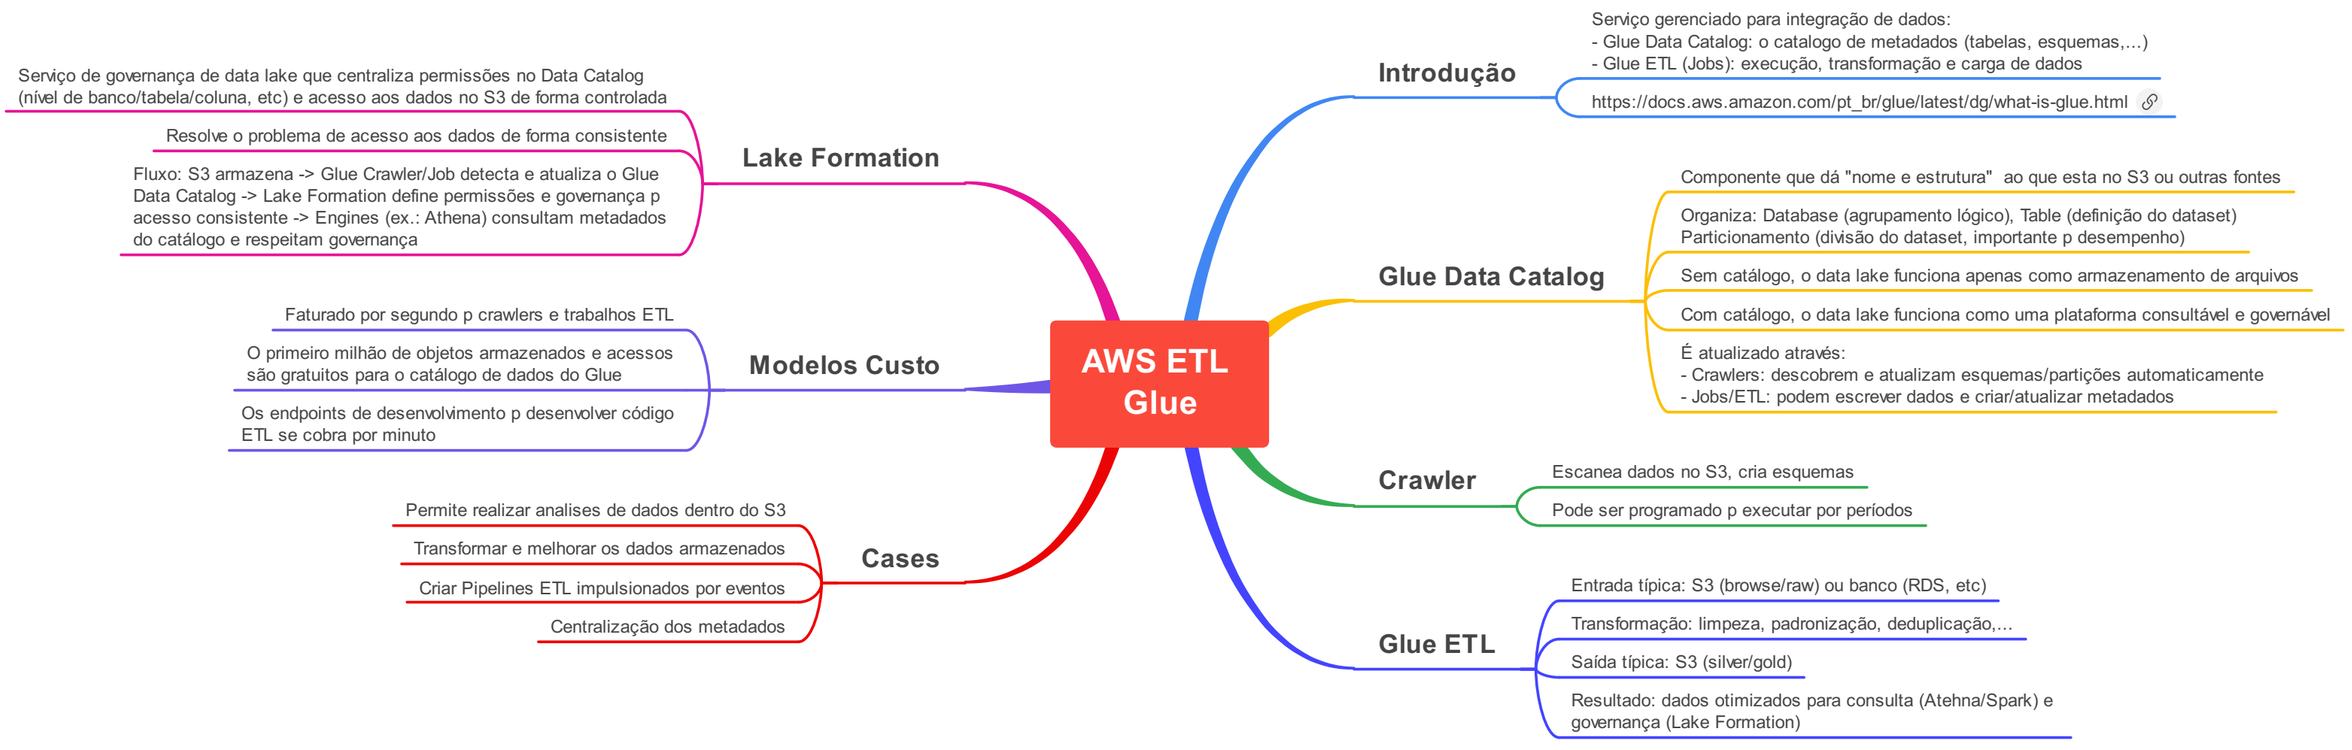
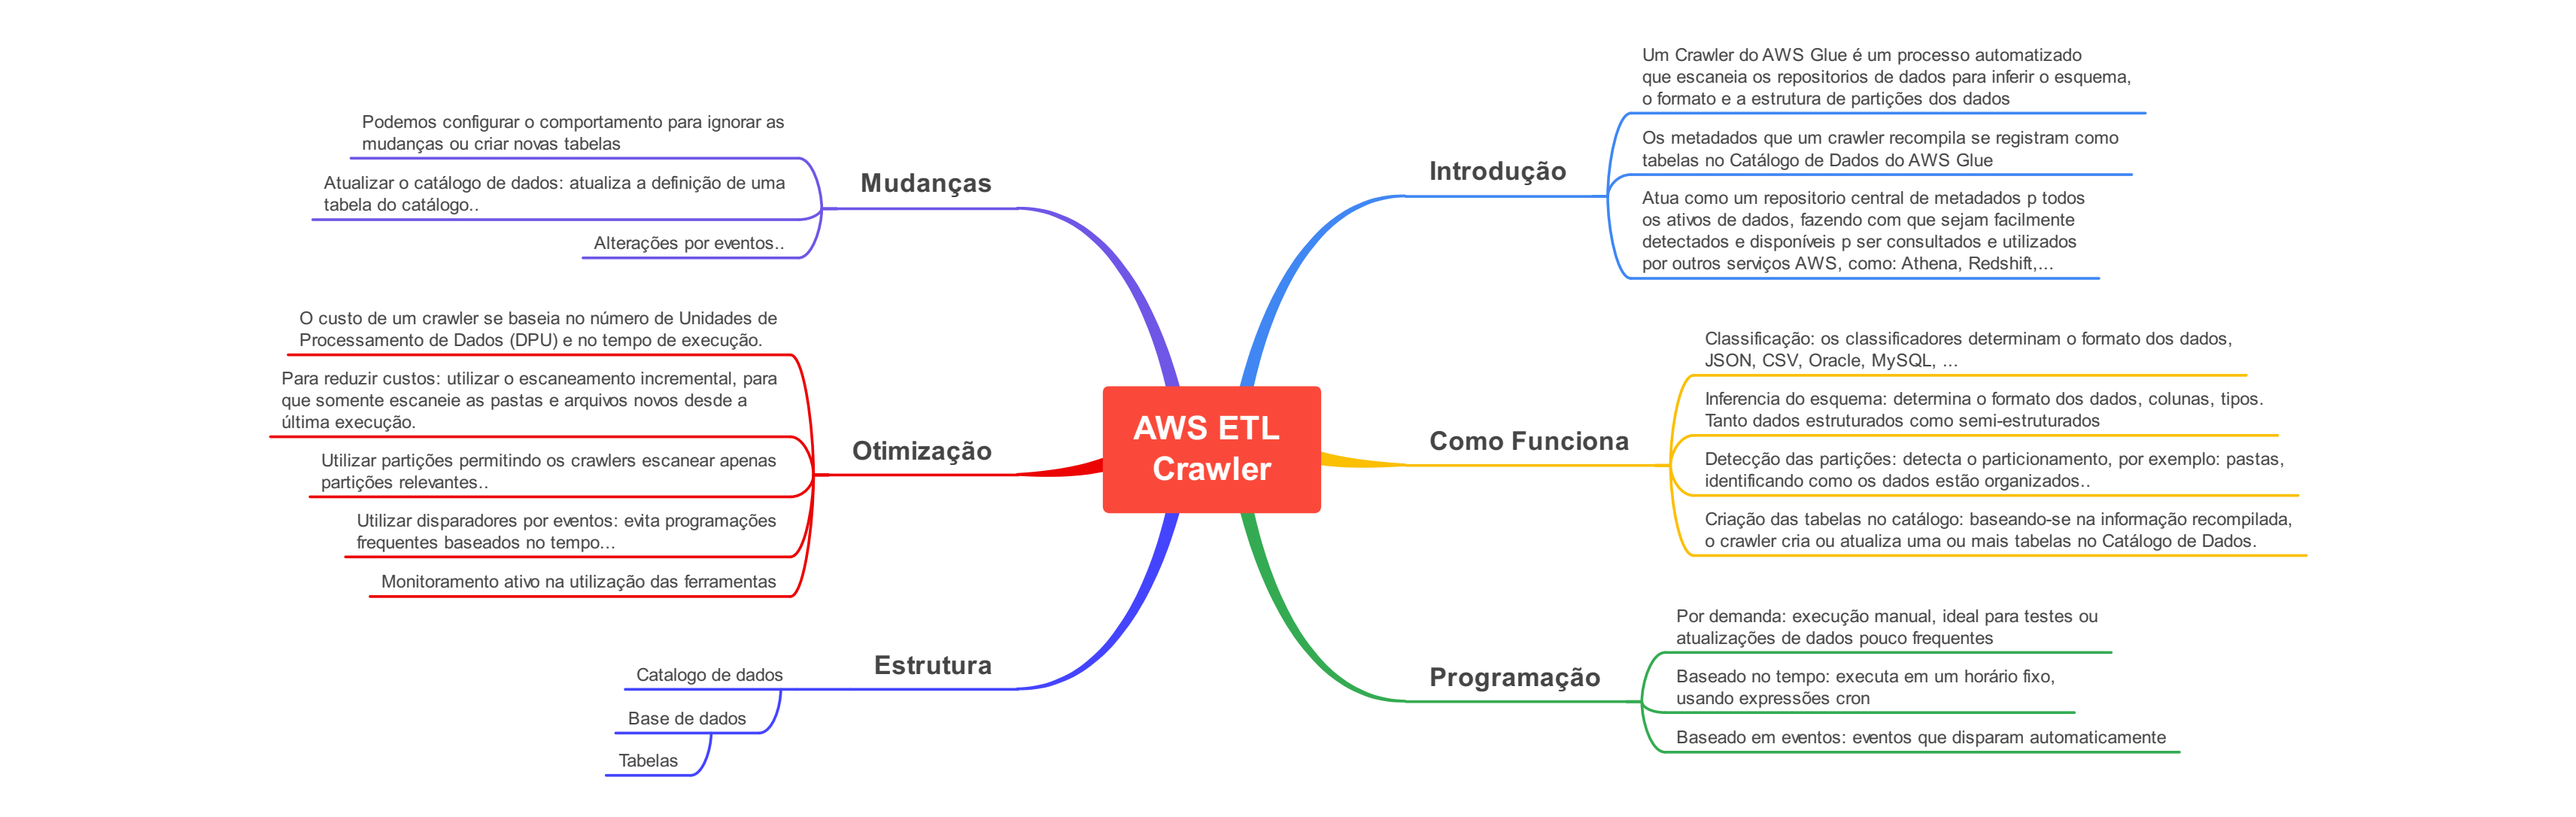

AWS ETL Glue
Introdução
Serviço gerenciado para integração de dados:
- Glue Data Catalog: o catalogo de metadados (tabelas, esquemas,...)
- Glue ETL (Jobs): execução, transformação e carga de dados
https://docs.aws.amazon.com/pt_br/glue/latest/dg/what-is-glue.html
Glue Data Catalog
Componente que dá "nome e estrutura" ao que esta no S3 ou outras fontes
Organiza: Database (agrupamento lógico), Table (definição do dataset)
Particionamento (divisão do dataset, importante p desempenho)
Sem catálogo, o data lake funciona apenas como armazenamento de arquivos
Com catálogo, o data lake funciona como uma plataforma consultável e governável
É atualizado através:
- Crawlers: descobrem e atualizam esquemas/partições automaticamente
- Jobs/ETL: podem escrever dados e criar/atualizar metadados
Crawler
Escanea dados no S3, cria esquemas
Pode ser programado p executar por períodos
Glue ETL
Entrada típica: S3 (browse/raw) ou banco (RDS, etc)
Transformação: limpeza, padronização, deduplicação,...
Saída típica: S3 (silver/gold)
Resultado: dados otimizados para consulta (Atehna/Spark) e governança (Lake Formation)
Cases
Permite realizar analises de dados dentro do S3
Transformar e melhorar os dados armazenados
Criar Pipelines ETL impulsionados por eventos
Centralização dos metadados
Modelos Custo
Faturado por segundo p crawlers e trabalhos ETL
O primeiro milhão de objetos armazenados e acessos são gratuitos para o catálogo de dados do Glue
Os endpoints de desenvolvimento p desenvolver código ETL se cobra por minuto
Lake Formation
Serviço de governança de data lake que centraliza permissões no Data Catalog (nível de banco/tabela/coluna, etc) e acesso aos dados no S3 de forma controlada
Resolve o problema de acesso aos dados de forma consistente
Fluxo: S3 armazena -> Glue Crawler/Job detecta e atualiza o Glue Data Catalog -> Lake Formation define permissões e governança p acesso consistente -> Engines (ex.: Athena) consultam metadados do catálogo e respeitam governança


AWS ETL Crawler
Introdução
Um Crawler do AWS Glue é um processo automatizado que escaneia os repositorios de dados para inferir o esquema, o formato e a estrutura de partições dos dados
Os metadados que um crawler recompila se registram como tabelas no Catálogo de Dados do AWS Glue
Atua como um repositorio central de metadados p todos os ativos de dados, fazendo com que sejam facilmente detectados e disponíveis p ser consultados e utilizados por outros serviços AWS, como: Athena, Redshift,...
Como Funciona
Classificação: os classificadores determinam o formato dos dados, JSON, CSV, Oracle, MySQL, ...
Inferencia do esquema: determina o formato dos dados, colunas, tipos. Tanto dados estruturados como semi-estruturados
Detecção das partições: detecta o particionamento, por exemplo: pastas, identificando como os dados estão organizados..
Criação das tabelas no catálogo: baseando-se na informação recompilada, o crawler cria ou atualiza uma ou mais tabelas no Catálogo de Dados.
Programação
Por demanda: execução manual, ideal para testes ou atualizações de dados pouco frequentes
Baseado no tempo: executa em um horário fixo, usando expressões cron
Baseado em eventos: eventos que disparam automaticamente
Estrutura
Catalogo de dados
Base de dados
Tabelas
Otimização
O custo de um crawler se baseia no número de Unidades de Processamento de Dados (DPU) e no tempo de execução.
Para reduzir custos: utilizar o escaneamento incremental, para que somente escaneie as pastas e arquivos novos desde a última execução.
Utilizar partições permitindo os crawlers escanear apenas partições relevantes..
Utilizar disparadores por eventos: evita programações frequentes baseados no tempo...
Monitoramento ativo na utilização das ferramentas
Mudanças
Podemos configurar o comportamento para ignorar as mudanças ou criar novas tabelas
Atualizar o catálogo de dados: atualiza a definição de uma tabela do catálogo..
Alterações por eventos..