AWS ETL S3

Introdução

- Serviço de armazenamento de objetos em nuvem que permite armazenar e recuperar qualquer quantidade de dados de forma escalável, durável e segura.
- Características: não é um sistema de arquivos tradicional, escalabilidade ilimitada, durabilidade, disponibilidade, custo baixo, integração com AWS
- Importante: base do Data Lake, armazenamento central, flexibilidade (suporte diversos formatos), performance integrada com outras tecnologias, governança (controle de acesso, versionamento e criptografia)

Buckets

- É um contêiner de nível superior que armazena objetos. Analogia como se fosse uma pasta raiz unica
- Nome deve ser globalmente único em toda AWS
- Nome deve conter apenas letras minúsculas, hífens
- Cada bucket está associado a uma região AWS
- Em uma conta pode haver múltiplos buckets
- Se a versão estiver ativada, cada versão tem um ID único

Objetos

- O que vai ser armazenado dentro do S3
- Tamanho máximo 5TB
- Cada objeto tem seu identificador (chave)
- Será armazenado dentro dos Buckets

IAM

- Controla o acesso ao S3
- O crontrole de acesso é realizado por politicas especificas
- Exemplo: permitir acesso apenas de um IP especifico, bloquear acesso público, permitir acesso de um serviço AWS
- Criptografia padrão gerenciada pela AWS

Casos Uso

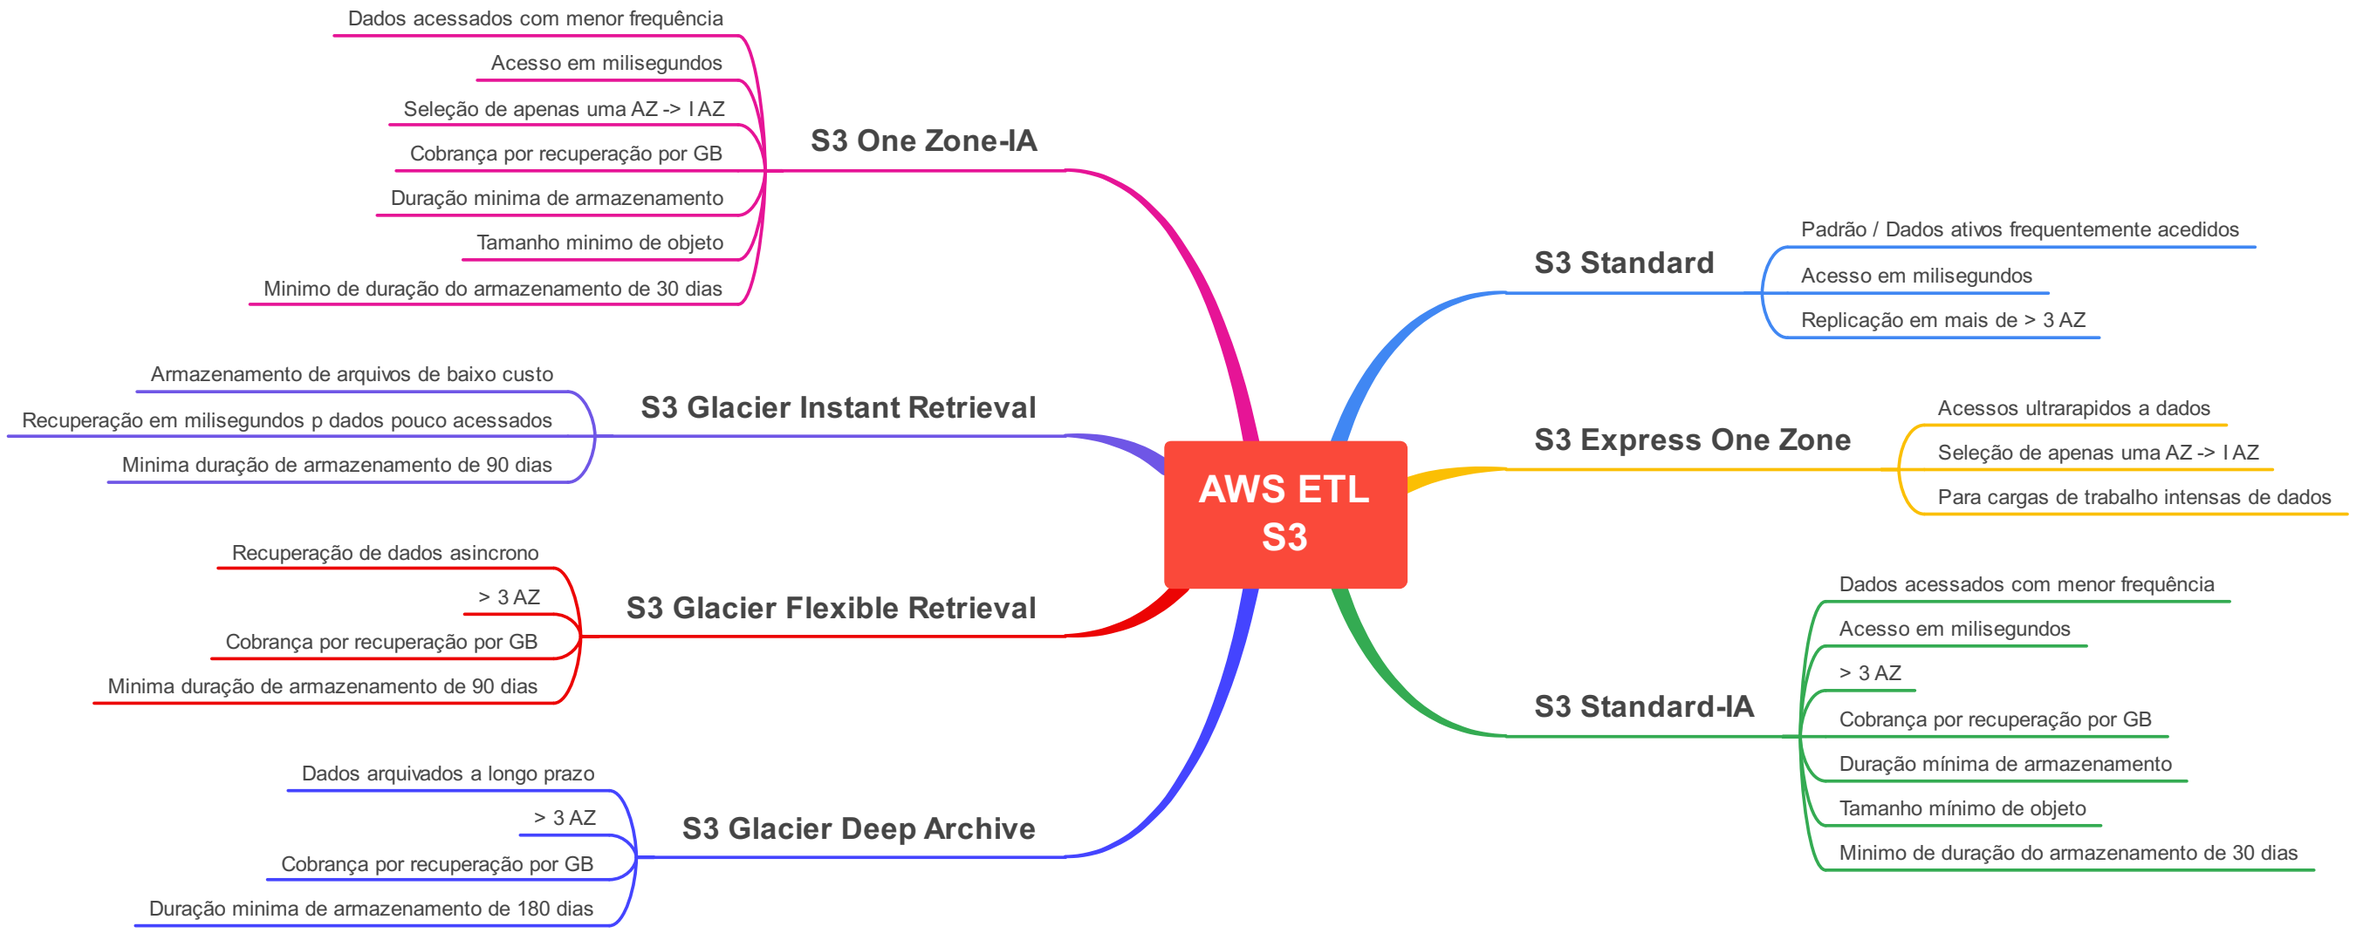
- Data Lake (bronze/silver/gold)
- Backup e disaster revovery
- Data Lake para Machine Learning
- Logs e monitoramento
- Integração com BI
- Páginas webs estáticas

Classes

- S3 Standard: mais caro, disponibilidade 99.99%¨, latência imediata, uso de dados acessados frequentemente (dados de produção, logs recentes, datasets em análise,...)
- S3 Standard Infrequent Access: custo mais barato, mas cobra por acesso, disponibilidade 99.99%, latência imediata, uso de dados acessados ocasionalmente backups, dados +30 dias (arquivos históricos, dados de auditoria,...)
- S3 Glacier (Archive): custo mais baratro, latência minutos a horas (recuperação lenta), uso de dados raramente acessados, conformidade regulatória (backups de longo prazo, dados de conformidade,..)
- Intelligent-Tiering: custo variável (move dados entre classes conforme acesso), uso quando o padrão de utilização é desconhecido, benefício de otimizar custo automaticamente

Políticas acesso

- Resource: bucket, objeto a que se aplica a política
- Effect: efeito obtido quando o usuário solicita a ação específica, que pode permitir ou negar
- Actions: conjunto de operações p cada recurso
- Principal: conta o usuário com permissão de acesso


AWS ETL
S3
S3 Standard
Padrão / Dados ativos frequentemente acedidos
Acesso em milisegundos
Replicação em mais de > 3 AZ
S3 Express One Zone
Acessos ultrarapidos a dados
Seleção de apenas uma AZ -> I AZ
Para cargas de trabalho intensas de dados
S3 Standard-IA
Dados acessados com menor frequência
Acesso em milisegundos
> 3 AZ
Cobrança por recuperação por GB
Duração mínima de armazenamento
Tamanho mínimo de objeto
Minimo de duração do armazenamento de 30 dias
S3 One Zone-IA
Dados acessados com menor frequência
Acesso em milisegundos
Seleção de apenas uma AZ -> I AZ
Cobrança por recuperação por GB
Duração minima de armazenamento
Tamanho minimo de objeto
Minimo de duração do armazenamento de 30 dias
S3 Glacier Instant Retrieval
Armazenamento de arquivos de baixo custo
Recuperação em milisegundos p dados pouco acessados
Minima duração de armazenamento de 90 dias
S3 Glacier Flexible Retrieval
Recuperação de dados asincrono
> 3 AZ
Cobrança por recuperação por GB
Minima duração de armazenamento de 90 dias
S3 Glacier Deep Archive
Dados arquivados a longo prazo
> 3 AZ
Cobrança por recuperação por GB
Duração minima de armazenamento de 180 dias