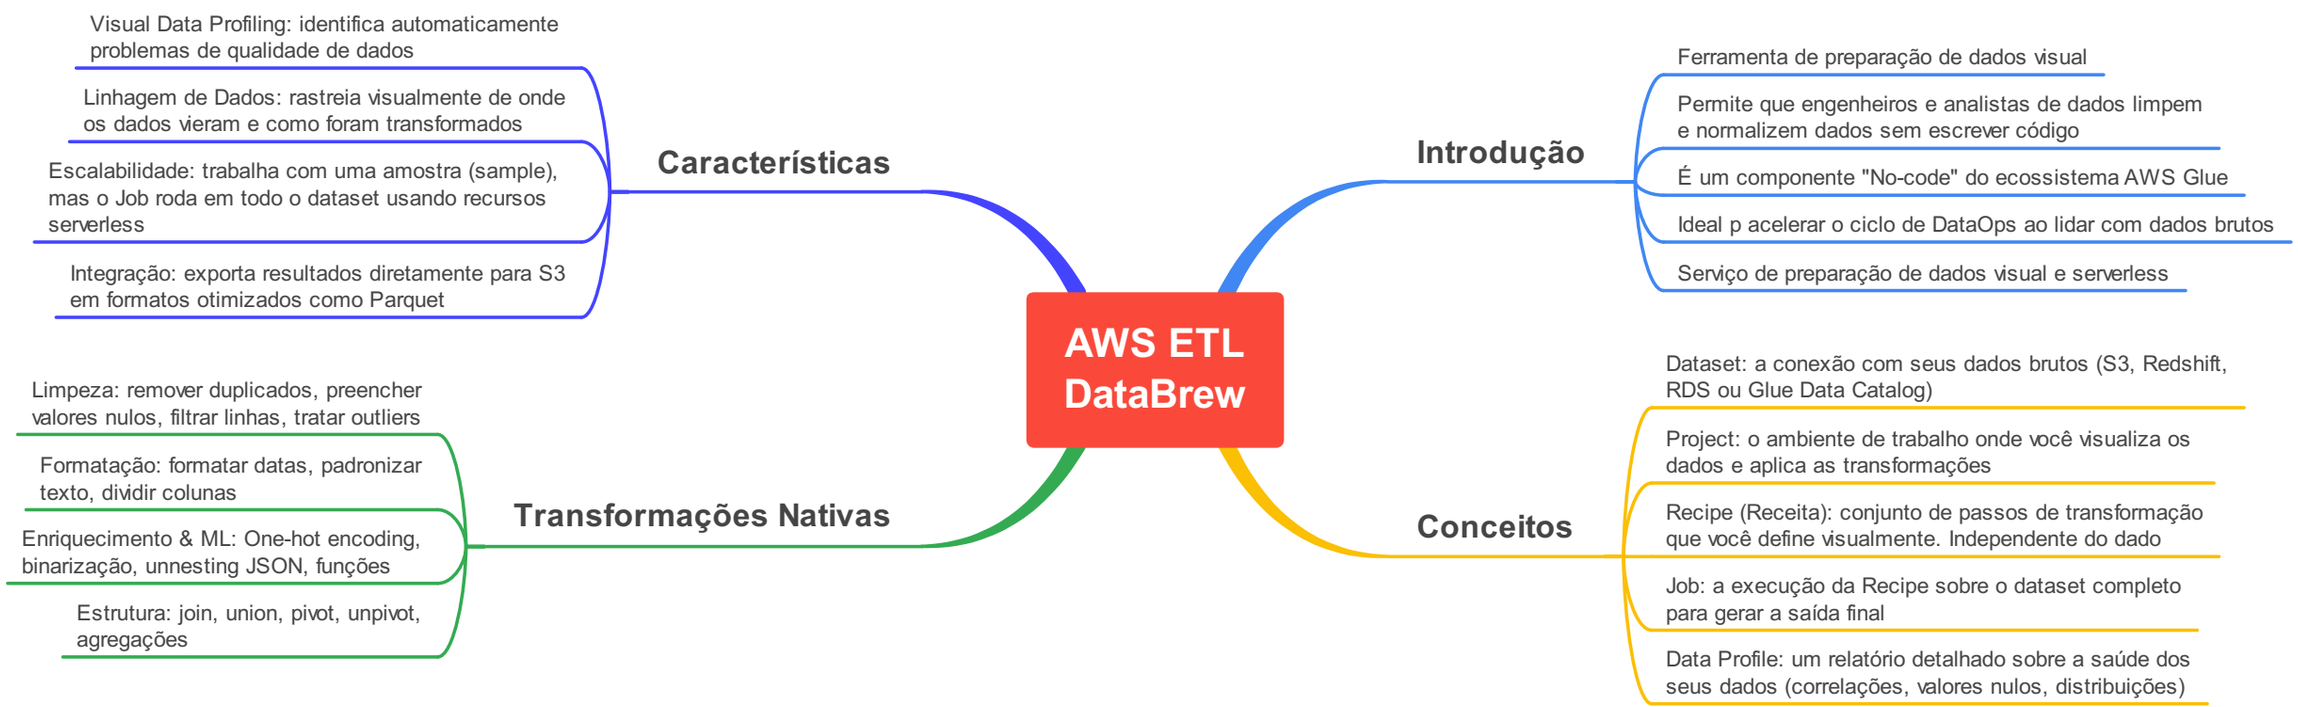
AWS ETL DataBrew
Introdução
Ferramenta de preparação de dados visual
Permite que engenheiros e analistas de dados limpem e normalizem dados sem escrever código
É um componente "No-code" do ecossistema AWS Glue
Ideal p acelerar o ciclo de DataOps ao lidar com dados brutos
Serviço de preparação de dados visual e serverless
Conceitos
Dataset: a conexão com seus dados brutos (S3, Redshift, RDS ou Glue Data Catalog)
Project: o ambiente de trabalho onde você visualiza os dados e aplica as transformações
Recipe (Receita): conjunto de passos de transformação que você define visualmente. Independente do dado
Job: a execução da Recipe sobre o dataset completo para gerar a saída final
Data Profile: um relatório detalhado sobre a saúde dos seus dados (correlações, valores nulos, distribuições)
Características
Visual Data Profiling: identifica automaticamente problemas de qualidade de dados
Linhagem de Dados: rastreia visualmente de onde os dados vieram e como foram transformados
Escalabilidade: trabalha com uma amostra (sample), mas o Job roda em todo o dataset usando recursos serverless
Integração: exporta resultados diretamente para S3 em formatos otimizados como Parquet
Transformações Nativas
Limpeza: remover duplicados, preencher valores nulos, filtrar linhas, tratar outliers
Formatação: formatar datas, padronizar texto, dividir colunas
Enriquecimento & ML: One-hot encoding, binarização, unnesting JSON, funções
Estrutura: join, union, pivot, unpivot, agregações

AWS ETL
Glue x DataBrew
AWS DataBrew
Público-Alvo: analistas de dados/ cientistas
Interface: visual de planilha (No-Code)
Frequência: exploração e limpeza ad-hoc
Escalabilidade: alta (baseada em Jobs visual)
Foco: perfilamento visual e descoberta de padrões
AWS Glue
Público-Alvo: engenheiros de dados (DevOps)
Interface: código ou visual (pipeline)
Frequência: execução contínua em produção
Escalabilidade: altíssima (Spark Nativo)
Foco: validação automática e regras rígidas

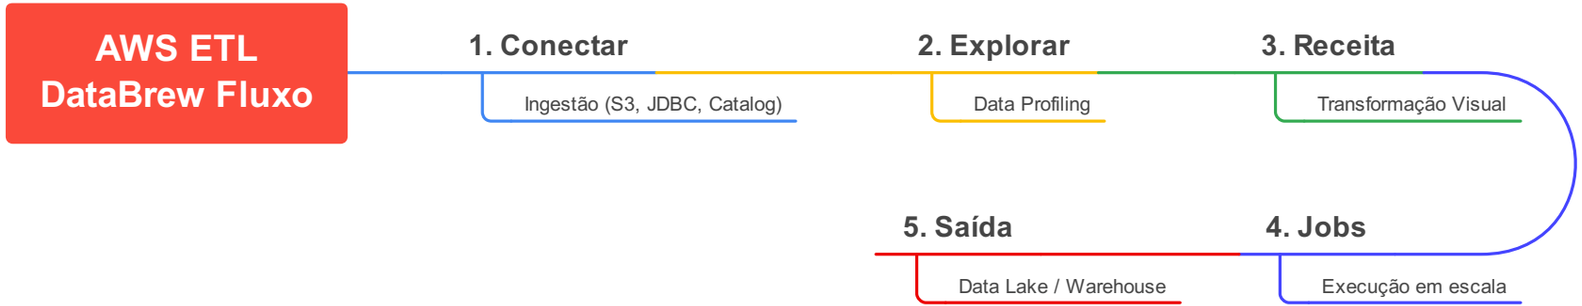
AWS ETL
DataBrew Fluxo
1. Conectar
Ingestão (S3, JDBC, Catalog)
2. Explorar
Data Profiling
3. Receita
Transformação Visual
4. Jobs
Execução em escala
5. Saída
Data Lake / Warehouse